

西北农林科技大学

2026 届本科生毕业论文（设计）

中期研究进展报告

题 目：基于 RAG 方法的苹果专业知识智能问答系统及 Web 实现

学 院：园艺学院

专 业：果树专业

年级班级：2022 级 5 班

学生姓名：葛帅

学 号：2022010637

指导教师：赵涛 教授

2026 年 3 月

一、文献综述

1.1 RAG 技术研究现状

检索增强生成（Retrieval-Augmented Generation, RAG）是一种将信息检索与大语言模型生成能力相结合的技术框架，近年来在知识密集型任务中展现出显著优势。Lewis 等人于 2020 年首次提出 RAG 范式，其核心思想是在生成回答之前，先从外部知识库中检索与用户查询相关的文档片段，将其作为上下文信息注入大语言模型（LLM）的输入中，从而使生成结果更加准确、可靠且具有事实依据。这种方法有效缓解了 LLM 存在的幻觉问题和知识时效性不足的局限。

RAG 框架通常由三个核心组件构成：索引（Indexing）、检索（Retrieval）和生成（Generation）。索引阶段将文档切分为语义块并通过嵌入模型（如 BERT、Sentence-Transformers 等）转换为向量表示，存储于向量数据库中；检索阶段根据用户查询的向量表示，从向量数据库中检索最相似的文档片段；生成阶段将检索到的上下文与原始查询一同输入 LLM，生成最终回答。

在技术演进方面，RAG 经历了从朴素 RAG（Naive RAG）到高级 RAG（Advanced RAG）再到模块化 RAG（Modular RAG）的发展过程。朴素 RAG 采用简单的检索-生成流水线；高级 RAG 引入了查询改写、重排序（Re-Ranking）等优化策略，显著提升了检索质量；模块化 RAG 则将检索和生成过程拆解为可灵活组合的功能模块，支持更复杂的推理链路。当前主流的 RAG 实现工具包括 LangChain 和 LlamaIndex，它们提供了完整的 RAG 开发框架，支持多种向量数据库（如 Qdrant、FAISS、Chroma、Milvus 等）和 LLM 接口的集成。在向量数据库方面，Qdrant 因其高性能的相似度搜索能力、灵活的过滤机制和良好的 API 设计，成为近年来备受关注的开源向量搜索引擎。

1.2 RAG 在农业领域的应用

RAG 技术在农业领域的应用正在快速拓展。2024 年，Yang 等人提出了 ShizishanGPT，一种整合知识图谱和 RAG 的农业大语言模型，面向作物种植场景的智能问答，支持多模态数据的处理与融合。Liu 等人提出了基于语义检索增强生成

的玉米种植知识问答模型 Sem-RAG，通过重排序策略在小规模农业 QA 数据集上提升了模型响应精度。

在国内，2025 年 Wang 等人构建了融合 LLM 与知识图谱的水稻病虫害专家系统，利用 RAG 技术提升知识构建效率和问答的泛化能力。Wu 等人提出了多模态融合大模型 Agri-QA Net，面向甘蓝等作物的知识问答，强调精准知识筛选和协同生成的重要性。Yang 等人利用大语言模型从研究论文中提取果树病害知识，为构建果树领域专家系统提供了新的技术路径。

Siddiqui 等人将 RAG 与 YOLOv8 框架相结合，开发了面向精准农业的咖啡病害检测系统，验证了 RAG 在多模态农业场景中的可行性。Sapkota 等人的综述系统分析了多模态 LLM 在农业中的多种应用场景，包括果树病害检测和作物管理优化等方向，指出 RAG 技术在整合视觉和文本数据方面具有重要潜力。然而，目前针对苹果育种知识的 RAG 系统化应用仍较为匮乏。

1.3 苹果育种知识碎片化问题

苹果育种领域的知识呈现高度碎片化特征。在果实性状方面，研究论文多以单一性状为焦点，如果实硬度（firmness）相关的遗传基础研究涉及 MdNAC18.1、MdEXP-A1 等基因的功能鉴定，成熟期调控涉及 MdNAC5 等转录因子的表达分析，而酸度、糖度、颜色等性状的遗传机制则分散于不同的研究团队和期刊中。这种碎片化导致育种者难以快速构建跨性状的综合育种方案。

在果实大小方面，相关文献分散于遗传基础（如基因组关联分析 GWAS）和环境影响因素（如光照、水分、肥料）两个维度，缺乏将多因素整合的系统框架。在病害抗性方面，研究主要聚焦于苹果黑星病、褐斑病等病害的分子机制，但病害抗性与果实品质性状的交叉影响研究较为稀少。此外，不同研究间的品种样本重叠较少，实验条件差异较大，导致研究结论的横向比较和整合面临显著困难。

这种碎片化不仅源于研究方法的多样性（如 GWAS、转录组学、QTL 定位等），还受限于数据共享平台的缺乏和数据格式的不统一。因此，利用 RAG 等人工智能技术，将分散于各类文献和数据库中的苹果育种知识进行系统整合，构建结构化的知识检索与问答系统，具有迫切的现实需求和重要的应用价值。

1.4 Web 智能问答系统技术路线

现代 Web 智能问答系统通常采用前后端分离的架构设计。前端方面，Next.js 作为 React 的全栈框架，提供了服务端渲染（SSR）、静态生成（SSG）和 API 路由等特性，在构建高性能交互式 Web 应用中表现优异。后端方面，FastAPI 框架基于 Python 的异步编程特性，具有高性能、自动生成 API 文档和完善的类型校验等优势，非常适合构建机器学习模型服务和向量检索服务的 API 层。

在向量存储层面，Qdrant 向量数据库支持高维向量的高效存储与近邻检索，提供了灵活的过滤和分组机制，并支持通过 Docker 进行独立部署。嵌入模型方面，Sentence-Transformers 系列（如 all-MiniLM-L6-v2）提供了轻量级但效果优良的文本向量化方案。在大语言模型方面，DeepSeek 等国产大模型 API 提供了高质量的中文语言理解和生成能力。容器化部署（Docker Compose）技术可以将前端、后端和数据库服务统一编排管理，确保系统的可移植性和一键部署能力。

二、取得的研究进展

2.1 总体进展概述

按照开题报告和任务书的进度安排，本毕业设计自 2025 年 10 月启动以来，已完成文献调研、知识库构建、RAG 后端核心开发以及 Web 前端集成等主要工作，整体进度符合预期。截至 2026 年 3 月，系统已实现完整的上传-导入-提问-证据回溯闭环，具备可演示状态，并完成了首轮系统评测。以下对各阶段的具体工作进展进行详细说明。

2.2 文献调研与知识库构建（2025 年 10 月至 12 月）

2.2.1 文献数据采集

在知识库构建阶段，系统收集了 47 篇苹果育种相关英文文献及中文论文，其中包括 26 篇主文献和 21 份补充材料。文献内容涵盖苹果果实硬度（firmness）、成熟期（maturity）、酸度（acidity）、糖度（sugar content）、颜色（color）、抗病性（disease resistance）等核心性状的遗传基础研究。涉及的关键基因包括 MdNAC18.1、MdNAC5、MdEXP-A1、MdERF3、MdERF118 等，为知识库提供了坚实的科学基础。

2.2.2 结构化数据处理

除文献数据外，还整理了候选基因位点的表格数据。编写 Python 脚本将原始数据转换为结构化 CSV 格式，按性状类别（如硬度、酸度、颜色等）拆分为独立子集，便于后续的分类检索和精准匹配。数据预处理过程中，对表头重复行、空行和非结构化注释进行了初步清理，确保导入向量数据库后的数据质量。

2.2.3 向量数据库构建

采用 Qdrant 向量数据库存储论文与基因数据的嵌入向量。嵌入模型选用 sentence-transformers/all-MiniLM-L6-v2，该模型在语义相似度任务上表现稳定，向量维度为 384 维。系统在首次启动时自动检测并创建 papers、genes、genes_firmness 三个集合（Collection），分别存储论文文本向量、全量基因数

据向量和硬度相关基因数据向量。论文 PDF 经解析后按段落切分为文本块，基因 CSV 数据按行转换为文本描述，均通过嵌入模型转换为向量后导入 Qdrant。

2.3 RAG 后端开发（2026 年 1 月至 2 月）

2.3.1 后端架构设计

后端服务基于 FastAPI 框架搭建，采用异步处理机制以提升并发性能。系统架构遵循模块化设计原则，将数据导入、向量检索、重排序和 LLM 生成等功能解耦为独立模块。主要 API 接口包括：论文 PDF 上传与解析接口、基因 CSV/TSV 上传与导入接口、问答查询接口以及会话管理接口。FastAPI 自动生成的 OpenAPI 文档为前后端联调提供了便利。

2.3.2 自动路由检索机制

检索模块实现了智能路由机制（auto/papers/genes/hybrid 四种模式）。在 auto 模式下，系统根据用户问题中的关键词自动判断检索目标：当问题涉及基因名称或位点信息时，优先检索 genes 集合；当问题偏向文献综述或机制描述时，检索 papers 集合；对于综合性问题，则同时检索多个集合并融合结果。这一机制显著提升了不同类型查询的检索精度。

2.3.3 Rerank 重排序策略

针对苹果育种领域的检索特点，设计了专项 Rerank 重排序策略。以硬度（firmness）相关查询为例，系统对检索结果中包含正向关键词（如 firmness、texture、crispness、MdNAC18.1 等）的文档进行加权，同时对包含病害噪声关键词的文档进行降权处理。该策略在硬度类问题的检索测试中效果显著，有效过滤了与查询主题无关的干扰文档，提升了检索结果的精准度。

2.3.4 LLM 生成模块

生成模块接入 DeepSeek 大语言模型 API，负责根据检索到的上下文信息和用户查询生成最终回答。在提示词（Prompt）设计方面，要求模型将回答按证据强度分层组织：Level A 为直接证据（如基因位于目标性状的 QTL 区域内且为差异表达基因），Level B 为间接证据（如功能注释、表达模式分析、同源基因信息等）。

每条证据均附引用编号，支持用户追溯原始文献来源。这种分层回答机制提升了回答的科学严谨性和可验证性。

2.4 Web 前端开发与集成（2026 年 2 月至 3 月）

2.4.1 前端界面实现

Web 前端采用 Next.js 框架构建，实现了双栏聊天布局，包括左侧会话列表和右侧消息流展示区域。用户可以创建多个独立会话，每个会话保持独立的对话历史。问答交互区域支持文本输入和发送，系统回答以结构化格式呈现，证据部分采用折叠展示设计，用户可按需展开查看具体的检索证据来源。

2.4.2 数据上传功能

前端实现了两类数据上传功能：（1）论文 PDF 上传，支持多文件批量上传，上传后自动触发后端的 PDF 解析和向量化入库流程；（2）基因 CSV/TSV 文件上传，上传后自动导入至 Qdrant 向量数据库的对应集合中。上传过程提供进度反馈，导入完成后用户即可基于新数据进行问答查询。

2.4.3 容器化部署

系统通过 Docker Compose 统一管理三个服务容器：FastAPI 后端服务、Next.js 前端服务和 Qdrant 向量数据库服务。编写了完整的 docker-compose.yml 配置文件，定义了服务间的网络通信、数据卷挂载和环境变量配置，实现了一键启动和部署。该方案确保了系统的跨平台兼容性和环境一致性，便于在不同机器上进行演示和测试。

2.5 系统评测（2026 年 3 月）

设计了 20 道苹果育种领域的评测题，覆盖果实硬度、成熟期、酸度、糖度、颜色和抗病性等多个性状方向，完成了首轮自动评测。评测结果显示，硬度类问题的检索召回明显改善，系统能够准确定位到相关基因（如 MD16G1117200、MD16G1096900 等）所在的 QTL 区域信息，并按 Level A 和 Level B 分层给出回答。但非硬度性状（如酸度、糖度、颜色）的评测中仍存在证据不足的情况，反映出当

前知识库在这些性状方向上的文献覆盖面有限。评测日志已完整记录，具备可复现性。

2.6 项目管理

项目代码托管于 GitHub，建立了规范的协作开发流程，包括分支管理策略、.gitignore 配置优化和 README 文档的持续更新。代码结构清晰，后端和前端代码分别组织在独立目录中，便于维护和迭代。

2.7 当前存在的问题

在项目推进过程中，主要存在以下问题：

（1）非硬度性状的检索证据不足。当前知识库以硬度和成熟期相关文献为主，酸度、糖度、颜色等其他性状的文献覆盖面有限，导致相关问题回答时证据支撑薄弱。

（2）基因数据表中存在噪声行干扰。部分 CSV 文件包含表头重复行、空行或非结构化注释，在向量化后产生低质量检索结果，需要进一步清洗和过滤。

（3）Embedding 模型对中英文混合查询的语义理解有限。当前使用的 all-MiniLM-L6-v2 为英文预训练模型，对中文育种术语的嵌入效果不够理想，存在语义漂移问题。

（4）缺乏系统化的自动评测指标。目前评测以人工判断为主，尚未实现 Precision@K、证据命中率等定量指标的自动计算。

2.8 下一步工作计划

根据项目进度安排，后续工作将集中在以下几个方面：

（1）扩充知识库覆盖范围（2026 年 3 月下旬）：补充酸度、糖度、颜色等性状的文献和基因数据，完善 trait 分类和查询意图识别机制，提升系统对多性状问题的回答能力。

（2）优化数据清洗与结构化抽取流程（2026 年 4 月上旬）：改进基因表格的预处理脚本，过滤噪声行，引入更严格的结构化证据模板，降低无关内容对检索结果的干扰。

（3）实现自动化评测体系（2026 年 4 月中旬）：编写自动评测脚本，计算 Precision@K、证据命中率等定量指标，建立可复现的评测基准，为系统优化提供量化依据。

（4）增加会话持久化与报告导出功能（2026 年 4 月下旬）：支持历史会话的持久化保存和育种分析报告的导出，提升系统的实用价值。

（5）撰写毕业设计论文（2026 年 4 月至 5 月）：整理系统设计文档、实验数据和评测结果，按学校要求完成毕业论文撰写。

（6）答辩准备（2026 年 5 月）：制作演示 PPT，准备系统现场演示和答辩材料。

三、参考文献

- [1] Lewis P, Perez E, Piktus A, et al. Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks[J]. Advances in Neural Information Processing Systems, 2020, 33: 9459-9474.
- [2] Gao Y, Xiong Y, Gao X, et al. Retrieval-Augmented Generation for Large Language Models: A Survey[J]. arXiv preprint arXiv:2312.10997, 2024.
- [3] Yang S, Liu Z, Mayer W. ShizishanGPT: An Agricultural Large Language Model Integrating Tools and Resources[J]. arXiv preprint arXiv:2409.13537, 2024.
- [4] Liu X, Chen H, Wang Z. Research on Sem-RAG: A Corn Planting Knowledge Question Answering Model Based on Semantic Retrieval Augmentation Generation[J]. Applied Sciences, 2025, 15(19): 10850.
- [5] Wang J, Zhang L, Li H, et al. Rice pest and disease expert system based on Large language models and Retrieval-Augmented Generation[J]. Transactions of the Chinese Society of Agricultural Engineering, 2025.
- [6] Wu H, Zhao C, Li J. Agri-QA Net: Multimodal Fusion Large Language Model Architecture for Crop Knowledge Question-Answering System[J]. Smart Agriculture, 2025.
- [7] Yang X, Li J, Wang S. Extracting Fruit Disease Knowledge from Research Papers Based on Large Language Models[J]. Applied Sciences, 2025, 15(2): 628.
- [8] Siddiqui S A, Ansari M S, Salman M, et al. A RAG-Augmented YOLOv8 Framework for Coffee Disease Detection in Precision Agriculture[J]. arXiv preprint arXiv:2505.21544, 2025.
- [9] Siddiqui S A, Ansari M S, Salman M, et al. Overcoming LLM Challenges using RAG-Driven Precision in Coffee Leaf Disease Remediation[J]. arXiv preprint arXiv:2405.01310, 2024.
- [10] Sapkota R, Ramezani M, Naeini E K. Multi-Modal LLMs in Agriculture: A Comprehensive Review[J]. TechRxiv preprint, 2025.
- [11] Sapkota R, Ramezani M, Naeini E K. Harnessing large vision and language models in agriculture: a review[J]. Frontiers in Plant Science, 2025.
- [12] Wang Y, Li X, Chen Z. A review on enhancing agricultural intelligence with large language models[J]. Artificial Intelligence in Agriculture, 2025.
- [13] Li X, Wang Y, Zhang L. A large language model for multimodal identification of crop diseases and pests[J]. Scientific Reports, 2025, 15: 01908.
- [14] Zhang Y, Li J, Wang S. AgroLLM: Connecting Farmers and Agricultural Practices through Large Language Models[J]. arXiv preprint arXiv:2503.04788, 2025.
- [15] Qian M, Yan Y, Jiang Y, et al. Research Progress on Genetic Basis of Fruit Quality Traits in Apple[J]. Frontiers in Plant Science, 2022, 13: 918210.

- [16] Migicovsky Z, et al. Genomic prediction of fruit texture and training population optimization towards the application of genomic selection in apple[J]. Horticulture Research, 2020, 7: 148.
- [17] Zhang L, Xu J, Li Y. MYB transcription factors regulate fruit size in apple (*Malus domestica*)[J]. Plant Biotechnology Journal, 2023, 21(5): 1052-1064.
- [18] Leforestier D, et al. Genomic basis of the differences between cider and dessert apple varieties[J]. Evolutionary Applications, 2015, 8(7): 650-661.
- [19] Pettoello C, et al. Autochthonous Apple Cultivars from the Campania Region (Southern Italy): Bio-Agronomic and Qualitative Traits[J]. Plants, 2023, 12(5): 1168.
- [20] Johansson E, Lindstrom A. Retrieval-Augmented Generation (RAG) for Automating Agricultural Block Boundary Adjustment Annotations[M]. Master's thesis, Linkoping University, 2025.

四、外文翻译

原文出处: Lewis P, Perez E, Piktus A, et al. Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks[C]. Advances in Neural Information Processing Systems (NeurIPS), 2020, 33: 9459-9474.

面向知识密集型 NLP 任务的检索增强生成

摘要

大规模预训练语言模型已被证明能够在其参数中存储事实性知识，并在下游 NLP 任务上微调后取得最先进的结果。然而，这类模型访问和精确操控知识的能力仍然有限，因此在知识密集型任务上，其性能落后于针对特定任务设计的架构。此外，为模型决策提供可溯源性以及更新其世界知识仍然是亟待解决的研究问题。具有可微分访问机制以显式获取非参数记忆的预训练模型迄今仅在抽取式下游任务中进行了探索。本文探索了一种通用的检索增强生成（RAG）微调方法，该模型将预训练的参数记忆与非参数记忆相结合用于语言生成。我们提出的 RAG 模型中，参数记忆为预训练的序列到序列模型，非参数记忆为维基百科的稠密向量索引，通过预训练的神经检索器进行访问。我们比较了两种 RAG 方案：一种在整个生成序列中基于相同的检索段落进行条件生成，另一种则可以针对每个生成词元使用不同的段落。我们在多种知识密集型 NLP 任务上对模型进行微调和评估，并在三个开放域问答任务上取得了最先进的结果，超越了参数化序列到序列模型和针对特定任务的检索-抽取架构。在语言生成任务中，我们发现 RAG 模型比最先进的纯参数序列到序列基线模型生成更加具体、多样和真实的语言。

1 引言

预训练神经语言模型已被证明能够从数据中学习大量深层知识。它们无需访问任何外部记忆即可实现这一点，作为参数化的隐式知识库运行。虽然这一进展令人振奋，但此类模型确实存在不足之处：它们无法轻松扩展或修订自身的记忆，难以直接为其预测提供可解释的洞察，并且可能产生“幻觉”现象。将参数记忆与非参数（即基于检索的）记忆相结合的混合模型可以解决其中一些问题，因为知识可以被直接修订和扩展，且被访问的知识可以被检查和解释。REALM 和 ORQA 是两个最近

提出的模型，它们将掩码语言模型与可微分检索器相结合，已展现出令人期待的结果，但仅在开放域抽取式问答任务中进行了探索。

在本文中，我们将混合参数和非参数记忆引入 NLP 的核心工具——序列到序列（seq2seq）模型。我们通过一种通用的微调方法为预训练的参数记忆生成模型赋予非参数记忆，我们将此方法称为检索增强生成（RAG）。我们构建的 RAG 模型中，参数记忆是一个预训练的 seq2seq Transformer，非参数记忆是维基百科的稠密向量索引，通过预训练的神经检索器进行访问。我们在一个端到端训练的概率模型中将这些组件组合起来。检索器（稠密段落检索器 DPR）根据输入提供潜在文档，seq2seq 模型（BART）随后基于这些潜在文档和输入生成输出。我们通过 Top-K 近似对潜在文档进行边际化，可以按输出层面（假设同一文档负责所有词元）或按词元层面（不同文档负责不同词元）进行。与 T5 或 BART 一样，RAG 可以在任何 seq2seq 任务上进行微调，其中生成器和检索器可以联合学习。

我们的结果突出了将参数和非参数记忆与生成相结合在知识密集型任务上的优势——这类任务是人类在没有外部知识源的情况下无法合理完成的。我们的 RAG 模型在开放域 Natural Questions、WebQuestions 和 CuratedTrec 上取得了最先进的结果，并在 TriviaQA 上显著优于使用专门预训练目标的近期方法。尽管这些是抽取式任务，我们发现无约束的生成方法优于先前的抽取式方法。在知识密集型生成任务中，我们在 MS-MARCO 和 Jeopardy 问题生成上进行了实验，发现我们的模型生成的回答比 BART 基线更加真实、具体和多样。在 FEVER 事实验证任务上，我们的结果与使用强检索监督的最先进流水线模型仅相差 4.3%。最后，我们展示了非参数记忆可以被替换以在世界变化时更新模型的知识。

2 方法

我们探索的 RAG 模型使用输入序列 x 检索文本文档 z ，并在生成目标序列 y 时将其用作附加上下文。我们的模型利用两个组件：（i）检索器，其参数为 η ，根据查询 x 返回文本段落上的（Top-K 截断）分布；（ii）生成器，其参数为 θ ，基于前 $i-1$ 个词元、原始输入 x 和检索到的段落 z 生成当前词元。为了端到端训练检索器和生成器，我们将检索到的文档视为潜在变量。我们提出了两种以不同方式对潜在文档进行边际化的模型，以产生生成文本上的分布。

RAG-Sequence 模型使用同一检索文档生成完整序列。从技术上讲，它将检索到的文档视为单一潜在变量，通过 Top-K 近似进行边际化以获得 seq2seq 概率。具体而言，使用检索器检索 Top-K 个文档，生成器为每个文档产生输出序列概率，然后进行边际化。RAG-Token 模型则可以为每个目标词元选取不同的潜在文档并进行相应的边际化。这使得生成器在产生答案时可以从多个文档中选择内容。

检索组件基于 DPR（稠密段落检索器）构建。DPR 采用双编码器架构：文档编码器基于 BERT-BASE 产生文档的稠密表示，查询编码器同样基于 BERT-BASE 产生查询表示。计算具有最高先验概率的 K 个文档列表是一个最大内积搜索（MIPS）问题，可以在亚线性时间内近似求解。我们使用 DPR 的预训练双编码器来初始化检索器并构建文档索引。

生成器组件可以使用任何编码器-解码器建模。我们使用 BART-large，一个拥有 4 亿参数的预训练 seq2seq Transformer。在从 BART 生成时，为了将输入 x 与检索内容 z 结合，我们简单地将它们拼接起来。BART 通过去噪目标和多种不同的噪声函数进行预训练，在多种生成任务上取得了最先进的结果。

在训练过程中，我们联合训练检索器和生成器组件，无需关于应检索哪些文档的直接监督。给定由输入/输出对组成的微调训练语料库，我们使用随机梯度下降和 Adam 优化器最小化每个目标的负边际对数似然。在训练期间更新文档编码器的成本较高，因为这需要像 REALM 在预训练期间那样定期更新文档索引。我们发现这一步骤对于获得强性能并非必要，因此保持文档编码器（和索引）固定，仅微调查询编码器和 BART 生成器。

3 实验

我们在多种知识密集型任务上对 RAG 进行了实验。对于所有实验，我们使用单一维基百科转储作为非参数知识源。每篇维基百科文章被切分为不重叠的 100 词文本块，共计 2100 万个文档。我们使用文档编码器计算每个文档的嵌入向量，并使用 FAISS 构建单一的 MIPS 索引，采用分层可导航小世界近似进行快速检索。在训练期间，我们为每个查询检索 Top-K 个文档，考虑 K 取 5 或 10 的情况。

在开放域问答实验中，我们将问题和答案视为输入-输出文本对，通过直接最小化答案的负对数似然来训练 RAG。我们将 RAG 与流行的抽取式问答范式进行比较，

后者从检索到的文档中提取答案跨度，主要依赖非参数知识。我们还与“闭卷问答”方法进行比较，这些方法与 RAG 一样生成答案，但不利用检索，完全依赖参数知识。我们考虑了四个流行的开放域问答数据集：Natural Questions、TriviaQA、WebQuestions 和 CuratedTrec。

此外，RAG 模型可以超越简单的抽取式问答，以自由形式的生成文本回答问题。为测试 RAG 在知识密集型设置中的自然语言生成能力，我们使用了 MS-MARCO NLG 任务。为评估 RAG 在非问答设置中的生成能力，我们研究了开放域问题生成任务，提出了更具挑战性的 Jeopardy 问题生成任务。我们还在 FEVER 事实验证数据集上进行了实验，该任务要求判断自然语言声明是否被维基百科支持或反驳。

4 结果与分析

在所有四个开放域问答任务上，RAG 均取得了新的最先进结果。RAG 结合了“闭卷”（纯参数）方法的生成灵活性和“开卷”基于检索方法的性能优势。值得注意的是，RAG 的检索器使用 DPR 的检索器初始化。RAG 证明了无需重排序器或抽取式阅读器即可实现最先进性能。生成答案相比抽取答案存在多项优势：包含答案线索但不包含逐字答案的文档仍能贡献于正确答案的生成，这在标准抽取式方法中是不可能的。此外，即使正确答案不在任何检索到的文档中，RAG 也能生成正确答案，在 Natural Questions 上此类情况的准确率达 11.8%。

在抽象式问答方面，RAG-Sequence 在开放域 MS-MARCO NLG 任务上比 BART 高出 2.6 个 BLEU 分和 2.6 个 Rouge-L 分。在 Jeopardy 问题生成的人类评估中，评估者认为 BART 比 RAG 更真实的情况仅占 7.1%，而 RAG 比 BART 更真实的情况占 42.7%，清楚地证明了 RAG 在该任务上相对于最先进生成模型的有效性。评估者还发现 RAG 生成的内容显著更加具体。

我们还分析了 RAG 的检索消融实验。冻结检索器的实验表明，学习检索可以改善所有任务的结果。将 RAG 的稠密检索器与基于词重叠的 BM25 检索器进行比较，结果显示可微分检索在除 FEVER 以外的所有任务上均有改善。我们展示了非参数记忆的热插拔能力：通过简单替换知识索引，RAG 的世界知识即可更新，无需重新训练。在世界领导人变更的测试中，使用匹配年份索引的准确率约 70%，而使用不匹配索引的准确率仅为 4%至 12%，证实了这一机制的有效性。

5 讨论

在本文中，我们提出了具有参数和非参数记忆访问能力的混合生成模型。我们展示了 RAG 模型在开放域问答上取得了最先进的结果。我们发现人们更偏好 RAG 的生成内容而非纯参数的 BART，认为 RAG 更加真实和具体。我们对学习得到的检索组件进行了深入调查，验证了其有效性，并展示了检索索引可以通过热插拔来更新模型而无需任何重新训练。在未来工作中，探索两个组件是否可以从头开始联合预训练可能是富有成效的。我们的工作开辟了关于参数和非参数记忆如何交互以及如何最有效地结合它们的新研究方向，展现了其在广泛 NLP 任务中的应用前景。

该工作相比先前的研究提供了若干积极的社会效益：它更加牢固地以真实事实知识（本例中为维基百科）为基础，使其“幻觉”现象减少，生成更加真实的内容，并提供更多的控制和可解释性。RAG 可以应用于多种对社会有直接裨益的场景，例如为其配备医学索引并就该主题提出开放域问题，或帮助人们在工作中更加高效。